DHBW
Duale Hochschule
Baden-Württemberg
Karlsruhe

T3_3100

Konzeption und prototypische Implementierung eines Systems zur Synthese von Gesangsstimmen aus Text- und Melodieinformationen

Jannis Saur

<Datum>

Abstract

Die automatisierte Synthese von Sprache ist inzwischen weit verbreitet. Die Erzeugung einer Singstimme stellt jedoch zusätzliche Anforderungen, da neben dem gesprochenen Text auch musikalische Informationen wie Tonhöhe, Notendauer und Rhythmus berücksichtigt werden müssen. Im Rahmen dieser Studienarbeit werden verschiedene Ansätze zur Synthese einer Singstimme untersucht und miteinander verglichen werden. Dabei soll insbesondere betrachtet werden, wie sich unterschiedliche Verfahren zur Verarbeitung der sprachlichen und musikalischen Informationen auf das resultierende Audiosignal auswirken.

Anschließend soll eine prototypsiche Implementierung eienr dieser Verfahren erfolgen. Diese Implementierung wird dann in Form eines Singenden Roboters angewandt.

Eidesstattliche Erklärung

Gemäß § 20 Absatz 5 der Studien- und Prüfungsordnung für die Bachelor- und Masterstudiengänge der Dualen Hochschule Baden-Württemberg (DHBW StuPrO) vom 7. März 2024.

Hiermit versichere ich, dass ich die vorliegende Arbeit selbstständig verfasst und keine anderen als die angegebenen Quellen und Hilfsmittel verwendet habe und diese Arbeit bei keiner anderen Prüfung mit gleichem oder vergleichbarem Inhalt vorgelegt habe und diese bislang nicht veröffentlicht wurde.

Offenburg, den <Datum> gez. Jannis Saur

Ort, Datum Unterschrift

Allgemeine Hinweise

Aus Gründen der besseren Lesbarkeit wird in dieser Arbeit das generische Maskulinum verwendet. Sämtliche Personenbezeichnungen gelten gleichermaßen für alle Geschlechter. Zudem werden bestimmte Fachbegriffe aus der Softwareentwicklung in ihrer englischen Originalform verwendet. Insbesondere technische Begriffe aus dem Bereich Webentwicklung beibehalten, da diese im fachlichen Kontext etabliert sind und eine eindeutigere Beschreibung ermöglichen.

Inhaltsverzeichnis

1 Einleitung **1**

2 Grundlagen **2**
2.1 Produktion und Beschreibung gesprochener Sprache 2
2.2 Abgrenzung von Sprache und Gesang 3
2.3 Musikalische Beschreibung der Melodie 5
2.4 Digitale Darstellung des Schalls 5
2.5 Von Text und Melodie zum Audiosignal 6

3 Geplante Vorgehensweise **8**

4 Implementierung **9**

5 Evaluation und Vergleich **10**

6 Fazit und Ausblick **11**

7 Anhang **VI**

Abbildungsverzeichnis

Codeverzeichnis

Abkürzungsverzeichnis

API	Application Programming Interface

1 Einleitung

Einleitung ins Thema blablabla

2 Grundlagen

Dieses Kapitel legt die Begriffe fest, auf denen die spätere Konzeption des Synthesesystems aufbaut. Zuerst wird beschrieben, wie gesprochene Sprache erzeugt und in sprachliche Einheiten gegliedert wird. Danach folgt die Abgrenzung zum Gesang: Eine Singstimme nutzt dieselben Artikulationsorgane, Tonhöhe und Timing gibt jedoch die Melodie vor. Anschließend werden die musikalischen Größen eingeführt, die dafür nötig sind, und mit dem Text verbunden. Den Abschluss bilden die digitale Darstellung des Schalls und die Verarbeitungskette von Text und Melodie zum Audiosignal. Konkrete Verfahren und deren Vergleich sind nicht Gegenstand dieses Kapitels.

2.1 Produktion und Beschreibung gesprochener Sprache

Um im späteren verlauf die Synthese einer Gesangsstimme zu realisieren, wird zunächst die Gesprochene Sprache untersucht.

2.1.1 Stimmgebung und Artikulation

Beim sprechen, wird die Luft aus der Lunge gedrückt, dies gilt quasi als Energiequelle der gesprochenen Sprachen. Durch die vibration der Stimmbänder und der veränderung der Mundform entsteht letztendlich ein Ton.

Zusätlich zum erzeugten ton, bewegt man üblicherweise teile sienes Körpers um die gesprochene sprache zu unterstreichen. Dies ist allgemein als Artikulation bekannt. Dise Körperbewegung wirkt als ein lingusitisches Signal, vergleichbar mit einem audiosignal bei gesprochener sprache. Zusammen mit der gesprchenen sprache ergibt sich somit ein Gesammtbild, dass dem Empfänger erlaubt die nachricht zu rekonstruieren **anderson2022essentials**

- Lunge und Ausatemstrom als Energiequelle; subglottaler Druck.
- Phonation: Schwingung der Stimmlippen, daraus die Grundfrequenz.
- Artikulation: Zunge, Lippen, Kiefer und Gaumensegel verändern die Form des Vokaltrakts und damit den Klang.
- Stimmhafte und stimmlose Laute: periodische Anregung gegenüber Rauschanregung.
- Kurz halten: Das Gehör des Zuhörers wird nicht modelliert. Relevant ist die Erzeugung des Signals, nicht die Wahrnehmung im Innenohr.

Artikulation, Phonation und der Unterschied zwischen stimmhaften und stimmlosen Lauten folgen **anderson2022essentials**. Die Grundfrequenz als Folge der Stimmlippenschwingung beschreibt **jurafsky2026slp**.

2.1.2 Source-Filter-Modell

- Quelle: periodische oder rauschhafte Anregung an der Glottis.
- Filter: Resonanzen des Vokaltrakts, beschrieben über Formanten.
- Trennung von Anregung und Klangfarbe als gemeinsames Denkmodell vieler Syntheseverfahren.
- Grenze des Modells benennen: Es erklärt Vokale gut, Konsonanten und Übergänge nur vereinfacht.

Das Source-Filter-Modell und die Formanten folgen **fant1981sourcefilter** und **jurafsky2026slp**. Die technische Trennung von Anregung und Vokaltraktfilter in der Sprachverarbeitung beschreibt **backstrom2022speech**.

2.1.3 Sprachliche Einheiten

- Laut, Phonem und Silbe; die Silbe als Einheit, an die später Noten gebunden werden.
- Beziehung zwischen Schrift und Aussprache (Graphem zu Phonem), weil die Eingabe Text ist, das Signal aber Laute braucht.
- Prosodie: sprachliche Steuerung von Betonung, Intonation und Sprechtempo.
- Diese Prosodie wird im Gesang nicht frei geschätzt, sondern durch die Melodie ersetzt oder überlagert. Damit ist der Übergang zum nächsten Abschnitt begründet.

Phonem, Silbe und Betonung folgen **anderson2022essentials**. Den Zusammenhang von Schrift und Lautkette sowie die Tonhöhe als Ausdruck der Intonation beschreibt **jurafsky2026slp**.

2.2 Abgrenzung von Sprache und Gesang

Sprache und Gesang entstehen mit demselben Apparat. Der Abschnitt hält fest, welche Eigenschaften gemeinsam sind und welche die Synthese zusätzlich steuern muss.

2.2.1 Gemeinsame Grundlage

- Derselbe Artikulationsapparat und dasselbe Source-Filter-Prinzip.
- Verständlichkeit hängt an der Unterscheidbarkeit von Lauten, vor allem an Vokalen, Konsonanten und deren Übergängen.
- Gesang ist keine zweite Sprache, sondern eine andere zeitliche und tonhöhenbezogene Nutzung derselben Laute.

Gemeinsamer Artikulationsapparat, Formanten und die Abweichungen des Gesangs gegenüber der Sprechstimme folgen **sundberg1979singing**.

2.2.2 Tonhöhe und zeitliche Organisation

- Sprechen: Die Tonhöhe folgt der Intonation, sie ist relativ und verändert sich laufend.
- Singen: Die Tonhöhe folgt diskreten Tonstufen und wird über die Notendauer gehalten.
- Sprechen: Die Silbendauer ergibt sich aus Prosodie und Sprechtempo.
- Singen: Dauer und Einsatz folgen Takt, Tempo und Notenwerten.
- Vokale werden gedehnt, Konsonanten bleiben kurz. Das bestimmt, wie Text auf Noten verteilt werden kann.

Tonhöhe, Formantabstimmung und Phrasierung im Vergleich von Sprache und Gesang folgen **sundberg1979singing**.

2.2.3 Klangliche Eigenschaften der Singstimme

- Vibrato, Legato und gleitende Tonhöhenübergänge als Merkmale, die eine Singstimme von isolierten Tönen unterscheiden.
- Lautstärkeverlauf innerhalb einer Note.
- Einordnung, welche dieser Merkmale für Verständlichkeit nötig sind und welche nur die Natürlichkeit erhöhen. Die Priorität wird in der Konzeption festgelegt, hier nur benannt.

Vibrato, Phonation und Lautstärke der Singstimme folgen **sundberg1979singing**.

2.3 Musikalische Beschreibung der Melodie

Die Melodie ist die zweite Eingabe des Systems. Beschrieben werden nur Größen, die als Steuerdaten vorkommen: Tonhöhe, Dauer und ihre Zuordnung zum Text. Harmonielehre und Instrumentenkunde bleiben außen vor.

2.3.1 Tonhöhe, Tondauer und Rhythmus

- Tonhöhe als Frequenz und als musikalische Tonstufe einschließlich Oktavlage.
- Tondauer, Pause, Takt und Tempo.
- Zusammenhang von Grundfrequenz der Stimme und notierter Tonhöhe.
- Nur so viel zur Stimmung (gleichstufige Temperierung), wie nötig ist, um eine Note in eine Frequenz zu übersetzen.

Notierte Tonhöhe, Tondauer, Pausen, Takt und Tempo folgen **gotham2023openmusic**. Den Zusammenhang von notierter Tonhöhe und Grundfrequenz beschreibt **jurafsky2026slp**.

2.3.2 Zuordnung von Text und Melodie

- Regelfall: eine Silbe je Note.
- Melisma: eine Silbe über mehrere Noten.
- Folgen mehrerer Silben, die zeitlich an eine längere Note gebunden sind.
- Warum Text und Melodie getrennte Eingaben sind und vor der Synthese ausgerichtet werden müssen.

Die Silbe als Texteinheit beschreibt **anderson2022essentials**. Text und Melodie als gemeinsame Eingabe einer Gesangssynthese folgen **cho2021svs**.

2.4 Digitale Darstellung des Schalls

Das Ergebnis der Synthese ist ein digitales Audiosignal. Dieser Abschnitt definiert die Darstellungen, in denen eine Singstimme beschrieben und erzeugt wird.

2.4.1 Signal und Spektrum

- Schall als zeitlicher Verlauf des Schalldrucks; Abtastung und Abtastrate.

- Frequenzumfang, der für eine Singstimme relevant ist: Grundfrequenz und Obertöne.
- Kurzzeit-Spektrum und Spektrogramm als zeitlich aufgelöste Darstellung.
- Warum viele Verfahren nicht direkt die Wellenform, sondern eine spektrale Darstellung erzeugen und daraus das Signal rekonstruieren.

Abtastung, Kurzzeitspektrum und Spektrogramm folgen **backstrom2022speech**. Wellenform, Spektrum und das Sprachspektrogramm beschreibt ergänzend **jurafsky2026slp**.

2.4.2 Akustische Merkmale der Singstimme

- Verlauf der Grundfrequenz.
- Spektrale Hüllkurve als Träger der Klangfarbe und der Lautidentität.
- Stimmhaft gegenüber stimmlos, inklusive kurzer konsonantischer Abschnitte.
- Diese Merkmale als Zielgrößen zwischen der symbolischen Eingabe (Text, Noten) und dem hörbaren Signal.

Grundfrequenz, Formanten, stimmhafte und stimmlose Anregung sowie die spektrale Hüllkurve folgen **jurafsky2026slp**.

2.5 Von Text und Melodie zum Audiosignal

Die vorherigen Abschnitte laufen hier zusammen. Definiert wird die Verarbeitungskette, noch ohne ein konkretes Verfahren auszuwählen.

2.5.1 Sprachsynthese und Gesangssynthese

- Sprachsynthese: Aus Text wird Sprache, Tonhöhe und Dauer werden aus der Prosodie geschätzt.
- Gesangssynthese: Text und Melodie sind vorgegeben, Tonhöhe und Dauer sind Eingaben und keine Schätzgrößen.
- Folge für diese Arbeit: Ein Sprachsynthesesystem deckt die Aufgabe nicht ab, weil die musikalische Steuerung fehlt.

Sprachsynthese aus Text, bei der die prosodischen Verläufe erzeugt werden, beschreibt **backstrom2022speech**. Dass eine Gesangssynthese Tonhöhe und Rhythmus aus der musikalischen Vorlage übernimmt, folgt **cho2021svs**.

2.5.2 Verarbeitungskette

- Eingabe: Text in Schriftform oder als Lautfolge, Melodie als Folge von Notenereignissen.
- Sprachliche Analyse und Zuordnung von Silben zu Noten.
- Steuergrößen: Lautfolge, Grundfrequenz, Dauer, optional Lautstärke.
- Akustisches Modell: aus den Steuergrößen wird eine spektrale oder direkte Darstellung des Signals.
- Wellenformsynthese: daraus entsteht das abspielbare Audiosignal.
- Verweis: Welche Verfahren diese Schritte umsetzen und welches davon prototypisch gebaut wird, folgt in der geplanten Vorgehensweise und in der Evaluation.

Die Kette aus Textanalyse, akustischen Merkmalen und Wellenformsynthese folgt **backstrom2022speech**. Die entsprechende Kette für Gesang, vom Notentext über ein akustisches Modell zur Wellenform, beschreibt **cho2021svs**.

3 Geplante Vorgehensweise

<Inhalt hier>

4 Implementierung

<Inhalt hier>

5 Evaluation und Vergleich

<Inhalt hier>

6 Fazit und Ausblick

<Inhalt hier>

7 Anhang

<Anhang hier>

<Inhalt hier>